


REPASO - ESTADÍSTICA INFERENCIAL

1

DISTRIBUCIONES DE PROBABILIDAD - VAN PROBABILIDAD DE OCURRENCIA DE ALGÚN EVENTO

Normal



POISSON - DISCRETA - NÚMERO DE OBSERVACIONES EN CIERTO TIEMPO

Bernoulli - DISCRETA - ÉXITO y FRACASO

MONEDA

GEOMETRICA - NÚMERO DE FRACASOS ANTES DEL PRIMER ÉXITO

0.5
 p

0.5
 q

BINOMIAL - CONJUNTO DE BERNOULLI

$\rightarrow n =$ NÚMERO DE LANZAMIENTOS

EXPONENCIAL - CONTINUA - TIENE QUE VER CON LA POISSON.


TIEMPO QUE TRANSCURRE ANTES DE QUE OCURRA UN EVENTO EN UN PROCESO POISSON

ESTADÍSTICA INFERENCIAL

NOs INTERESA CONOCER LA ESTATISTICA PROMEDIO DE ESTUDIANTES UNIVERSITARIOS EN MÉXICO

POBLACIÓN - TODOS ESOS ALUMNOS

MUESTRA - SUBCONJUNTO DE ESOS ALUMNOS



ANTES DE OBSERVAR DATOS

(a) $X_1, X_2, \dots, X_n$ VARIABLES ALEATORIAS

n : # DE DATOS EN MI MUESTRA

(b) INDEPENDENCIA ENTRE VARIABLES // $P(A|B) = P(A)$

X_i NO AFECTA X_j //

(c) PROVIENEN DE UNA DISTRIBUCIÓN IDENTICA POBLACIONALES

$X_i \sim N(\mu, \sigma^2)$

DISTRIBUYE
COMO

$\rightarrow$ NORMAL

CON MEDIA = μ

CON VARIANZA = σ^2

CON AYUDA DE MI MUESTRA, QUIERO INFERIR ESOS
PARÁMETROS μ Y σ^2

HAY 3 FORMAS DE HACERLO

→ ESTIMACIÓN PUNTUAL PROPONER UNA FUNCIÓN DE ESTA
MUESTRA PARA ESTIMAR LOS PARÁMETROS
↓
ESTIMADOR/
ESTADÍSTICAS

(a) Media Muestral

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

PUNTO ALREDEDOR DEL CUAL SE CONCENTRAN LOS
DATOS

PROPIEDAD DE INSESGAMIENTO

- $E[\bar{x}] = \mu$

- $Var[\bar{x}] = \sigma^2/n$

NO ES INSESGADA

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\Rightarrow \bar{x}n = \sum_{i=1}^n x_i$$

SUMAR 12
ESTADÍSTICAS

SUMAR ESTADÍSTICAS
PROMEDIO
12 VECES

$$\Rightarrow n\bar{x} - \sum_{i=1}^n x_i = 0$$

n-COMPONENTE

n-COMPONENTES

$$\Rightarrow [\bar{x} + \bar{x} + \dots + \bar{x}] - [x_1 + x_2 + \dots + x_{12}] = 0$$

$$\Rightarrow [\bar{x} - x_1] + [\bar{x} - x_2] + \dots + [\bar{x} - x_{12}] = 0$$

Si ya conozco $\bar{x}$ y conozco $(n-1)$ DATOS
 1.65 ↓ ÚNICAMENTE 11 DATOS

YA PUEDO CONOCER EL ÚLTIMO VALOR FALTANTE

$n-1$: GRADOS DE LIBERTAD

(b) VARIANZA MUESTRAL:

$$s^2 = \frac{(\bar{x} - x_1)^2 + (\bar{x} - x_2)^2 + \dots + (\bar{x} - x_{12})^2}{n-1}$$

$$= \frac{\sum_{i=1}^n (\bar{x} - x_i)^2}{n-1} \rightarrow S_{xx}$$

~~$$E[s^2] = \sigma^2$$~~

INESGADA

(c) DESVIACIÓN ESTÁNDAR MUESTRAL:

$$s = \sqrt{s^2}$$

→ ESTIMACIÓN POR INTERVALOS

DEPENDEN DE LA MUESTRA. PARA CONSTRUIRLOS SE
REQUIEREN CANTIDADES PIVOTALES

↙
EN SU FÓRMULA INCLUYEN
PARÁMETROS POBLACIONALES
(DESCONOCIDOS)

↘
SU DISTRIBUCIÓN DE
PROBABILIDAD NO
LOS INCLUYE

$$\underline{X \sim N(\mu, \sigma^2)}$$

ESTANDARIZACIÓN:

PASO 1: RESTAR MEDIA

$$X - \mu$$

PASO 2: DIVIDIRLO ENTRE DESVIACIÓN

$$\frac{X - \mu}{\sigma}$$

$$\boxed{\frac{X - \mu}{\sigma}} \sim N(0, 1)$$



CANTIDAD PIVOTAL

INTERVALOS DE CONFIANZA

→ Encontrar μ conociendo σ^2

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

ESTANDARIZAR $\frac{\bar{x} - \mu}{\sqrt{\sigma^2/n}} = \sqrt{n} \left(\frac{\bar{x} - \mu}{\sigma} \right) \sim N(0, 1)$

NIVEL DE CONFIANZA
95%
↑

$$P\left(-a \leq \sqrt{n} \left(\frac{\bar{x} - \mu}{\sigma} \right) \leq a\right) = 1 - \alpha$$

NIVEL DE SIGNIFICANCIA


5%

NOTACIÓN $z_{\alpha/2}$

CUANTIL DE UNA NORMAL ESTÁNDAR EN $\alpha/2$

LA PROBABILIDAD DE SER MAYOR A

α ES $\alpha/2$



INTERVALO DE CONFIANZA


$$\mu \in \left[\bar{x} - \frac{\sigma}{\sqrt{n}} z^{(\alpha/2)}, \bar{x} + \frac{\sigma}{\sqrt{n}} z^{(\alpha/2)} \right]$$

// Si realizamos el experimento 100 veces y $1-\alpha$ es 95%, vamos a encontrar μ 95 de esas 100 veces en el intervalo que nos salga //

// Si $1-\alpha$ aumenta $\rightarrow$ El intervalo aumenta //

Con σ^2 desconocida

$$\sqrt{n} \left(\frac{\bar{x} - \mu}{\sigma} \right) \sim t_{(n-1)} \rightarrow \text{T-STUDENT CON } n-1 \text{ GRADOS DE LIBERTAD}$$



INTERVALO:

$$\left[\bar{X} - \frac{s}{\sqrt{n}} t_{(n-1)}^{(\alpha/2)}, \quad \bar{X} + \frac{s}{\sqrt{n}} t_{(n-1)}^{(\alpha/2)} \right]$$

→ PRUEBAS DE HIPÓTESIS

CONJETURA RESPECTO A PARÁMETROS POBLACIONALES

CONJETURA INICIAL

CONJETURA ALTERNATIVA

HIPÓTESIS NULA (H_0)

ESPECÍFICO
165 cm
↑

HIPÓTESIS ALTERNATIVA (H_1)

POS COLAS $H_0: \mu = \mu_0$ $H_1: \mu \neq \mu_0$

COLA IZQUIERDA $H_0: \mu > \mu_0$ $H_1: \mu \leq \mu_0$

COLA DERECHA $H_0: \mu < \mu_0$ $H_1: \mu \geq \mu_0$

DEBEMOS CREAR UNA REGLA DE DECISIÓN PARA
SABER SI RECHAZAMOS H_0

	H_0 VERDADERA	H_0 FALSA
RECHAZAR H_0	Error Tipo I (α)	No hay error ✓
No RECHAZAR H_0	No hay error ✓	Error Tipo II (β)

SE CONTROLA EL ERROR TIPO 1

$$\alpha = P(\text{Rechazamos } H_0 \mid H_0 \text{ cierta})$$

¿Si rechazamos o no? Construir región de rechazo
Utilizamos un estadístico de prueba

$$T = \sqrt{n} \left(\frac{\bar{x} - \mu_0}{s} \right) \sim t_{(n-1)}$$

↓
Suponiendo H_0 verdadera

Si T es grande en magnitud (positivo o negativo) nos da evidencia para rechazar H_0

Región de rechazo

$$H_0: \mu = \mu_0 \rightarrow 1.65$$

$$\text{Si } |T| > t_{(n-1)}^{\alpha/2}$$

Hay evidencia para rechazar H_0 a un nivel de significancia α

REGRESIÓN LINEAL SIMPLE

$x_1, x_2, \dots, x_n \rightarrow$ ESTATURAS (CUANTITATIVA $\mathbb{R}$)

$y_1, y_2, \dots, y_n \rightarrow$ PESOS (CUANTITATIVA $\mathbb{R}$)

$(x_1, y_1) \quad (x_2, y_2) \quad \dots \quad (x_n, y_n) \rightarrow$ TRAINING DATA

ANÁLISIS INDIVIDUAL

ME_{EDIA} ME_{UESTRAL}

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

$$\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$$

VARIANZA ME_{UESTRAL}

$$S_x^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \quad \text{with arrow pointing to } S_{xx}$$

$$S_y^2 = \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1} \quad \text{with arrow pointing to } S_{yy}$$

DESVIACIÓN ESTÁNDAR

$$S_x = \sqrt{S_x^2}$$

$$S_y = \sqrt{S_y^2}$$

COVARIANZA

$$\begin{aligned} \text{Cov}(x, y) &= \frac{(x_1 - \bar{x})(y_1 - \bar{y}) + (x_2 - \bar{x})(y_2 - \bar{y}) + \dots + (x_n - \bar{x})(y_n - \bar{y})}{n-1} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1} \rightarrow S_{xy} \end{aligned}$$

$$\widehat{\text{Cov}}(x, x) = \text{Var}(x)$$

$$S, \widehat{\text{Cov}}(x, y) > 0$$

RELACION POSITIVA PROPORCIONAL

$$S, \widehat{\text{Cov}}(x, y) < 0$$

RELACION NEGATIVA PROPORCIONAL

$$S, \widehat{\text{Cov}}(x, y) \approx 0$$

NO ENCONTRAMOS ESA TENDENCIA PROPORCIONAL
 $\Rightarrow$ NO HAY TENDENCIA LINEAL

COEFICIENTE DE CORRELACION DE PEARSON

$$\rho_{xy} = r_{xy} = \frac{\widehat{\text{Cov}}(x, y)}{s_x s_y}$$

$$-1 \leq r_{xy} \leq 1$$

y = PESOS




Perfect Positive
Correlation
 $r = 1$

x
//


ESTADUNAS




Strong Positive
Correlation
 $r = 0.8$



Weak Positive
Correlation
 $r = 0.5$



No
Correlation
 $r = 0$



Si $r_{xy} \approx 1$ $r_{xy} \approx -1$ SE PODRÍA PROPONER UNA RELACION
PARÁMETRICA:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

β_0 : INTERCEPTO
 β_1 : PENDIENTE DE LA RECTA
 ε : Error ESTOCÁSTICO // ALEATORIO //
 COMPONENTE SISTEMÁTICO (under $\beta_0 + \beta_1 x$)
 COMPONENTE IRREDUCIBLE (under ε)

$$y = f_{\beta}(x) + \varepsilon$$

MODELO DE REGRESIÓN LINEAL SIMPLE Y CONSIDERA
5 SUPUESTOS:

(1) LA RELACIÓN VERDADERA ENTRE AMBAS VARIABLES ES

$$y = \beta_0 + \beta_1 x + \varepsilon$$

β_0, β_1 : PARÁMETROS
POBLACIONALES DESCONOCIDOS


(2) x NO ES ESTOCÁSTICA // NO TIENE COMPORTAMIENTO ALEATORIO
TODO COMPORTAMIENTO ALEATORIO VIENE DE ε

(3) ε_i SON VARIABLES ALEATORIAS CON

$$E[\varepsilon_i] = 0 \quad \text{Var}[\varepsilon_i] = \sigma^2$$

(4) ε_i SON iid (INDEPENDIENTES IDENTICALMENTE DISTRIBUIDOS)

(5) ε_i SON NORMALES $\varepsilon_i \sim N(0, \sigma^2)$



ESTIMACIÓN POR MÍNIMOS CUADRADOS

→ PROPONER $\hat{\beta}_0, \hat{\beta}_1$ Y CALCULAR

$$\min_{\hat{\beta}_0, \hat{\beta}_1 \in \mathbb{R}} \sum_{i=1}^n \left(y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right)^2$$

RESIDUAL $\varepsilon_i = f(\hat{\beta}_0, \hat{\beta}_1)$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad \frac{s_{xy}}{s_{xx}}$$

ESTIMACIÓN POR MÁXIMA VEROSIMILITUD

YA CONOCEMOS LA DISTRIBUCIÓN Y BUSCAR PARÁMETROS QUE LLEVEN A QUE ESA DISTRIBUCIÓN SEA LO MÁS PARECIDA POSIBLE A NUESTROS DATOS

$$l(\beta_0, \beta_1, \sigma^2) = f(y_1, y_2, \dots, y_n) = f(y_1) f(y_2) \dots f(y_n)$$

FUNCIÓN
DE
DENSIDAD

INDEPENDENCIA $\beta_0 + \beta_1 x_i$

$$= \prod_{i=1}^n f(y_i) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\left(\frac{y_i - \mu_i}{\sigma}\right)^2}$$

LOG VEROSIMILITUD

y_i NO SON
IDÉNTICAMENTE
DISTRIBUIDAS

$$L = \ln(l(\beta_0, \beta_1, \sigma^2))$$

$\hat{\beta}_0$ y $\hat{\beta}_1$ SON LOS MISMOS QUE POR MÍNIMOS CUADRADOS

$$\hat{\sigma}_{MV}^2 = \frac{\sum_{i=1}^n (y_i - [\hat{\beta}_0 + \hat{\beta}_1 x_i])^2}{n}$$

e_i^2
RESIDUALES

NO ES INSUFICIENTE

$\Rightarrow$ RESTRICCIONES DE LOS RESIDUALES

$$\sum_{i=1}^n e_i = 0$$

$$\sum_{i=1}^n x_i e_i = 0$$

2 RESTRICCIONES

Si ya conozco $n-2$ RESIDUALES
PUEDO CONOCER LOS 2 QUE FALTAN

$n-2$: GRADOS DE LIBERTAD

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n e_i^2}{n-2}$$

$\rightarrow$ Si ES INSESGADA
 $E[\hat{\sigma}^2] = \sigma^2$

VARIANZAS

$$\begin{aligned} \text{ESTIMADAS} \quad \hat{\sigma}^2 \\ \text{Var}(\hat{\beta}_1) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} &\rightarrow \hat{\text{Var}}(\hat{\beta}_1) = \frac{\hat{\sigma}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \\ \text{Var}(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) &\rightarrow \hat{\text{Var}}(\hat{\beta}_0) = \hat{\sigma}^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) \\ \text{Var}(\hat{\sigma}^2) = \frac{2\sigma^4}{n-2} &\rightarrow \hat{\text{Var}}(\hat{\sigma}^2) = \frac{2\hat{\sigma}^4}{n-2} \end{aligned}$$

Error Estándar

$$Se(\hat{\beta}_1) = \sqrt{\hat{\text{Var}}(\hat{\beta}_1)}$$

$$Se(\hat{\beta}_0) = \sqrt{\hat{\text{Var}}(\hat{\beta}_0)}$$

$$Se(\hat{\sigma}^2) = \sqrt{\hat{\text{Var}}(\hat{\sigma}^2)}$$

INTERVALOS DE CONFIANZA

$$\beta_j \in \left[\hat{\beta}_j - \text{Se}(\hat{\beta}_j) \cdot t_{(n-2)}^{(\alpha/2)}, \hat{\beta}_j + \text{Se}(\hat{\beta}_j) \cdot t_{(n-2)}^{(\alpha/2)} \right]$$

PRUEBAS DE HIPÓTESIS

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon$$

$\downarrow$ VARIABLE DEPENDIENTE $\parallel$ 0 $\downarrow$ VARIABLE INDEPENDIENTE

$$H_0: \beta_j = 0$$

$$H_1: \beta_j \neq 0$$

ESTADÍSTICO DE PRUEBA

$$T = \frac{\hat{\beta}_j}{\text{Se}(\hat{\beta}_j)} \sim t_{(n-2)}$$



P-VALUE : PROBABILIDAD DE OBSERVAR UN ESTADÍSTICO AL MENOS TAN GRANDE COMO T DADO QUE H_0 ES CIERTA

Sí $p\text{-VALUE} \leq \alpha \rightarrow$ RECHAZO $H_0: \beta_j = 0$

Sí $p\text{-VALUE} > \alpha \rightarrow$ NO RECHAZO $H_0: \beta_j = 0$

COEFICIENTE DE DETERMINACIÓN

$$R^2 = r^2$$

↓
REGRESIÓN LINEAL
SIMPLE

R^2 : % DE VARIABILIDAD QUE
MI MODELO LOGRA EXPLICAR

$$R^2 \in [0, 1]$$

REGRESIÓN MÚLTIPLE

$$Y_i = \beta_0 + \beta_1 X_1 + \dots + \beta_n X_n + \epsilon_i$$

ESTATURA PESO EDAD MINIMIZAR

MÁS VARIABLES

SOBREAJUSTE

- No AÑADIR PREDICTORES INSIGNIFICANTES
- SUFICIENTE SENCILLO

MENOS VARIABLES

SUBAJUSTE

- FLEXIBLE
- No PUEDE EXPLICAR Y

MÁS VARIABLES → R^2 ENTRE MÁS GRANDE MEJOR

VA A CRECER O QUEDARSE IGUAL

$$R^2 \text{ AJUSTADA} \rightarrow R^2_a = 1 - \frac{(n-1)}{n-k-1} (1-R^2)$$

$n = \# \text{ DATOS}$
 $k = \# \text{ PREDICIONES}$

CRITERIOS DE INFORMACIÓN

POCOS DATOS * $AIC \text{ (AKAIKE)} = 2(k+1) - 2 \ln(L)$ ENTRE MÁS PEQUEÑO MEJOR

MÁS RESTRICTIVO * $BIC \text{ (BAYESIANO)} = \ln(L)(k+1) - 2 \ln(L)$

